层次化联邦学习中的动态协作模式选择

Dynamic Collaboration Mode Selection in Hierarchical Federated Learning

近两周工作汇报

从七模式联合误差建模，到三模式历史更新评分

杨婷婷　Tingting Yang

北京邮电大学　数学科学学院

2026 年 10 月 26 日

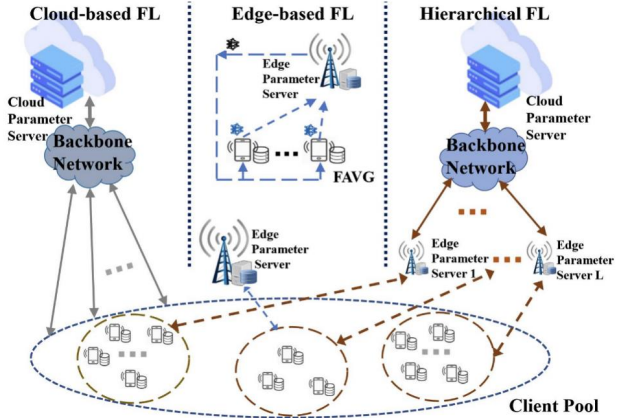
近两周完成的工作

01	**收敛研究范围**	从七模式误差建模，转向三种非 split 模式的历史更新评分。
02	**建立历史更新评分**	按模式维护历史偏差，用候选聚合单元的样本权重组合成 J。
03	**实现有限候选选择**	将 J 与估计时延归一化，比较 Greedy、迟滞和周期控制。
04	**形成实验与解释闭环**	完成 45 次主实验的结果整理，并分析训练量、通信与切换成本。

工作主线：定义可选模式 → 构造选择信号 → 实验验证与结果解释

依据：当前论文第 1、3、4、5 节

研究背景：三种联邦学习架构



云端联邦学习
客户端本地训练，更新直接汇聚到云端。

边缘联邦学习
客户端与 Edge 协作，由 Edge 完成聚合。

层次化联邦学习
先在 Edge 聚合，再由 Cloud 进行跨 Edge 聚合。

本研究关注：层次化系统中的动态协作模式选择

依据：联邦学习架构示意

初始目标：协调隐私、学习表现与效率

七模式协作重配置设想

- 同时考虑本地完整训练与跨层 split 训练。
- 改变执行位置、传输对象与聚合路径。
- 根据暴露信息考虑 DP 与 HE 保护。

希望解释不同协作与保护配置如何影响学习更新及系统代价。

含 split 训练的 4 种模式

$$\mathrm{LIE},\quad \mathrm{LIC},$$
$$\mathrm{LIEIIC},\quad \mathrm{LIEIIIC}$$

完整本地训练的 3 种模式

$$\mathrm{LIIE},\quad \mathrm{LIIC},\quad \mathrm{LIIEIIIC}$$

原方案以学习误差和时延为双目标，隐私与资源作为约束

依据：七模式稿：Model Construction 与 Global Multiobjective Collaborative Optimization；研究动机结合作者说明

关键困难：选择前如何评价联合学习误差

$$
\begin{aligned}
J^t_{\text{learn}} &= \mathbb{E}_t \|\Delta^t_s - \Delta^t_*\|_2^2 \\
&= \|e^t_{\text{alg}} + e^t_{\text{agg}} + b^t_s\|_2^2 + \operatorname{Tr}(V^t_s)
\end{aligned}
$$

- **无保护的反事实更新** $u^t_{i,0}$：同一候选配置下，无隐私保护时的更新参考。
- **理想梯度步** $\Delta^t_* = -\eta_t \nabla F(w^t)$：需要全局梯度参考。
- **扰动均值与协方差**：需要刻画加噪训练轨迹相对参考的统计差异。

旧稿主文采用 clean/private 配对校准；附录另有依赖额外假设的在线上界。

仅靠一次实际 DP 执行，难以直接得到候选的精确误差

依据：七模式稿：Joint Learning Error Modeling 与 Pre-decision online learning-error bound

本阶段调整：三种非 split 模式与历史选择信号

研究范围收敛

$$\mathcal{H} = \{\mathrm{FL}_E, \mathrm{FL}_{EC}, \mathrm{FL}_C\}$$

- 在客户端执行完整本地训练。
- 保留不同聚合路径及训练阶段。
- 保留 DP 与生命周期预算约束。

选择依据重构

$$d_k^\tau = u_{k,\mathrm{DP}}^\tau - v_g^{\tau-1}$$

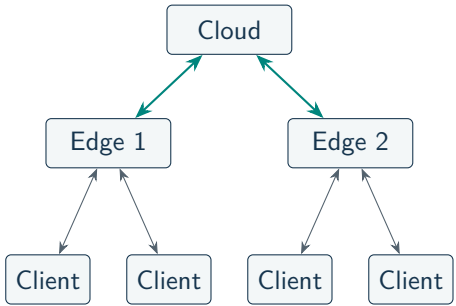
- 以 DP 历史更新估计模式偏差。
- 更新综合反映训练、数据、路径与保护机制的作用。
- 历史评分 J 偏好较大信号，J_{learn} 偏好较小误差。

当前研究定位

在资源与生命周期隐私约束下，用历史更新信号指导动态协作，
研究学习表现与系统时延之间的折中。

依据：当前三模式稿第 3.3.2 节与 Discussion；研究范围调整结合作者说明

研究问题：固定协作分配难适应异构条件



- **数据异构**：不同客户端的更新方向可能不同。
- **系统异构**：计算和内存存在异构，链路条件随轮次变化。
- **选择问题**：本轮应将多少客户端分配到哪种协作模式？

希望观察的关系

历史更新特征、系统时延与后续学习表现之间如何取舍？

依据：论文引言与系统模型；图为汇报用的架构示意

本阶段的研究切入点

已有研究方向	关注的问题	本阶段选择的切入点
异构 HFL	资源管理、模型适配、聚合控制	在三种协作模式之间选择客户端分配
多层协作	跨层训练、聚合与同步机制	用有限候选表示不同协作分布
隐私保护	DP 机制、预算管理与保护策略	将生命周期预算纳入候选可行性

本稿的具体方法

把模式相关的历史更新偏差与候选的聚合结构联系起来，
再结合估计系统时延，形成可执行的选择准则。

依据：论文第 2 节与第 1 节贡献概述

三种模式改变聚合路径与训练阶段

模式	流程	实验训练量
FL_E	本地训练 $\rightarrow$ Edge 聚合；Edge 模型返回客户端，更新向 Cloud 传播	1 阶段 $\times$ 2 步
FL_{EC}	本地训练与 Edge 聚合重复 E_B 次，再向 Cloud 提交最终更新	3 阶段 $\times$ 2 步
FL_C	本地训练后，直接向 Cloud 提交更新	1 阶段 $\times$ 2 步

- 数据始终保留在客户端；本地训练使用 DP-SGD。
- 同一轮中，不同客户端可以采用不同模式。
- 多阶段模式同时改变聚合过程与实际训练工作量。

依据：论文第 3.1 节，实验配置表 2

用 5 个候选分布表示可选择的客户端分配

候选	FL_E	FL_{EC}	FL_C	步数/轮
P_0	30%	30%	40%	320
P_1	50%	25%	25%	300
P_2	25%	50%	25%	400
P_3	25%	25%	50%	300
P_4	40%	40%	20%	360

每个候选先构造成实际分配

- 按 Edge 生成整数客户端配额。
- 检查资源、隐私和系统准入。
- 只比较当轮可行的候选。

每次最多评价 $M = 5$ 个候选。

标称比例经整数分配与调整；“步数/轮”是全体客户端本地训练步数之和。

依据：论文第 3.4 节与第 5.3.1 节

云更新单元：Cloud 实际聚合的更新对象

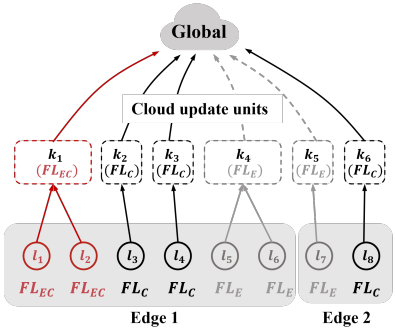
Cloud 将每份被接纳的更新作为一个聚合单元 k。

模式	单元对应的客户端	提交给 Cloud 的对象
FL_E	同一 Edge 中的该模式客户端组	Edge 聚合更新；异步发送，在接纳它的 Cloud 聚合中计入
FL_{EC}	同一 Edge 中的该模式客户端组	完成 E_B 阶段后的最终 Edge 更新
FL_C	每个客户端各自形成一个单元	该客户端直接提交的更新

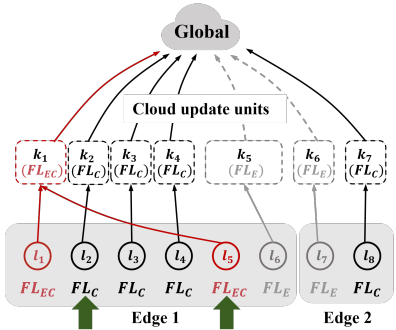
$\mathcal{K}^t(\mathbf{h}^t)$：本次 Cloud 聚合纳入的单元集合。
$m(k)$：单元 k 对应的协作模式。
依据：论文第 3.3.2 节：Cloud aggregation and weights

模式切换改变云更新单元的组成

切换前：6 个单元



切换后：7 个单元



- $l_2 : \mathrm{FL}_{EC} \to \mathrm{FL}_C$，从 Edge 组移出，独立形成 Cloud 更新单元。
- $l_5 : \mathrm{FL}_E \to \mathrm{FL}_{EC}$，与 l_1 组成新的 FL_{EC} 单元。

依据：论文第 3.3.2 节分组示意图；k_i 在各轮分别编号，同名不表示固定客户端组

单元样本权重如何接入历史评分

权重由单元代表的样本数确定

$$N_k^t = \sum_{i \in \mathcal{M}_k^t} n_i$$

$$l_k^t(\mathbf{h}^t) = \frac{N_k^t}{\sum_{\ell \in \mathcal{K}^t(\mathbf{h}^t)} N_\ell^t}$$

$\mathcal{M}_k^t$：单元 k 代表的客户端。
n_i：客户端 i 的训练样本数。
分母统计本次被接纳单元代表的总样本数。

对应前后分组示例

$$N_{k_1}^{t-1} = n_1 + n_2$$

$$N_{k_1}^t = n_1 + n_5, \qquad N_{k_2}^t = n_2$$

候选分配改变单元成员和模式，样本权重随之重新计算。

单元对历史评分的贡献：

$$l_k^t(\mathbf{h}^t)\, \widehat{d}_{m(k)}^t$$

候选决定当前单元与权重；历史提供按模式维护的偏差向量

依据：论文第 3.3.2 节：单元权重定义与历史偏差模型

历史更新如何成为候选选择信号



- 历史观测来自已执行的 DP 更新，保留训练与保护机制共同作用的特征。
- 候选分配改变单元组成与样本权重，进而改变历史偏差的组合。
- 评分使用决策前已有的历史信息；后续 loss 与 accuracy 用于实验评价。

J 刻画历史更新特征，为当前决策提供参考

依据：论文第 3.3.2 节

历史聚合更新偏差评分 J

$$D^t(\mathbf{h}) = \sum_{k \in \mathcal{K}^t(\mathbf{h})} I_k^t(\mathbf{h})\, \widehat{d}^t_{m(k)}$$

$$J^t(\mathbf{h}) = \frac{\|D^t(\mathbf{h})\|_2^2}{\left\|v_g^{t-1}\right\|_2^2 + \varepsilon_J}$$

- I_k：Cloud 更新单元的样本权重。
- $\widehat{d}_m$：模式 m 的历史偏差 EMA。
- v_g：历史全局更新参考。
- ε_J：数值稳定项。

较大 J 表示更强的聚合历史偏差贡献；其学习价值需要实验检验

依据：当前稿式 (26)–(27)；本页 J 是历史评分，区别于初始方案的 J_{learn}

用生命周期隐私预算约束训练

本地训练：样本级 DP-SGD

- 对逐样本梯度裁剪，再加入高斯噪声。
- RDP 账本累积实际执行的高斯机制。
- 模式训练阶段越多，需要计入的机制也越多。

$$\Phi_i^{t+1}(\alpha) = \Phi_i^t(\alpha) + \sum_{k=1}^{m_i^t} \frac{\alpha}{2(\sigma_{i,k}^t)^2}$$

实验配置

预算 $\bar{\epsilon} = 8$
$\delta = 10^{-5}$，裁剪阈值 $C = 1$

代表性噪声倍率：
$\mathrm{FL}_E, \mathrm{FL}_C$： 9.803
FL_{EC}： 16.979

倍率依据模式和剩余预算校准。

隐私进入候选可行性，也进入历史更新的观测来源

依据：论文第 3.2 节、实验配置表 2；RDP 核算不采用采样放大

联合效用：历史信号与系统时延的取舍

$$U^t(\mathbf{h};\lambda) = \underbrace{\lambda \frac{J^t(\mathbf{h}) - J^t_{\min}}{J^t_{\max} - J^t_{\min}}}_{\text{偏好更大的历史偏差贡献}} + \underbrace{(1-\lambda)\frac{T^t_{\max} - T_{\text{sys}}(\mathbf{h})}{T^t_{\max} - T^t_{\min}}}_{\text{偏好更小的估计时延}}$$

三种偏好设置

$\lambda = 0.25$：更偏重时延
$\lambda = 0.50$：两个归一化项等权
$\lambda = 0.75$：更偏重历史偏差信号

Greedy 规则

$$\mathbf{h}^{t,*} \in \arg\max_{\mathbf{h}\in\mathcal{C}^t} U^t(\mathbf{h};\lambda)$$

$\mathcal{C}^t$ 是当轮可行候选集合。

依据：论文式 (29)–(30)；某项最大值等于最小值时，该归一化项取 0.5

在线选择流程与切换控制

1. 前 5 轮执行 P_0 收集历史。
2. 第 6 轮起，构造可行候选。
3. 冻结历史，计算 J 与 T。
4. 归一化并计算联合效用。
5. 按策略选择，执行训练。
6. 更新历史统计与隐私账本。

策略	更新规则
Greedy	每轮选当前效用最大者
Hysteresis	改善超过 0.05 才切换
Periodic	每 5 轮允许一次新决策

保持规则可减少频繁重配置。
Hysteresis 与 Periodic 可能保留当前候选。

依据：论文算法 1 与第 5.2 节

实验设计：15 种策略，3 个种子，45 次主实验

数据与系统

Fashion-MNIST + LeNet-5
100 客户端，10 个 Edge，100 轮
非 IID：Dirichlet $\alpha = 0.5$
种子：42、43、44

策略覆盖

5 个固定候选 + 7 个动态策略
另加 3 个纯模式参考策略

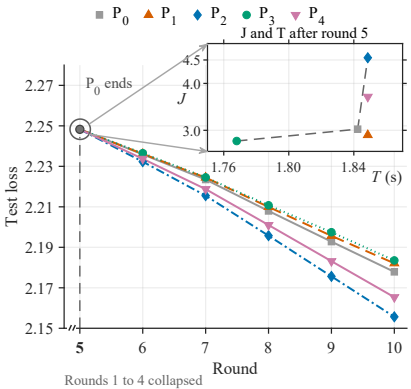
评价与统计口径

- Loss：第 100 轮测试损失。
- Accuracy：各 seed 先平均 91–100 轮，再跨 seed 汇总。
- 主实验：均值 ± 样本标准差。
- 记录系统时延、通信、训练步数与模式变化。

真实模型训练配合事件时延仿真；单种子短期 pilot 单独报告

依据：论文第 5.1–5.2 节、表 4；选择计算时间单独记录

相同起点下，历史分数与后续 loss 下降排序一致



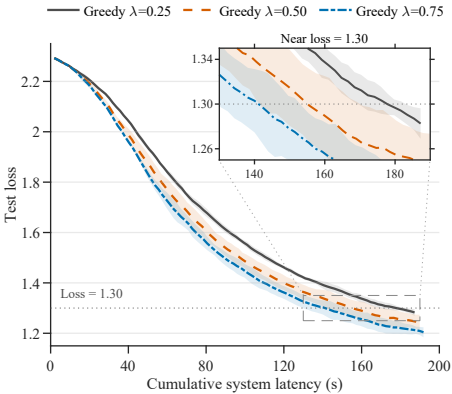
候选	初始 J	Loss 下降
P_2	4.5475	0.0926
P_4	3.7146	0.0829
P_0	3.0249	0.0704
P_1	2.8986	0.0662
P_3	2.7715	0.0648

共同 P_0 训练 5 轮，
再分别固定各候选训练 5 轮。

当前提供初步排序一致性证据。

依据：论文图 5 及 pilot 原始记录；seed42，每个候选一次延续运行

效用权重改变了学习曲线与累计时延



λ	最终 loss	总 T/s
0.25	1.2826	187.258
0.50	1.2412	189.896
0.75	1.2038	191.851

在本实验的三个权重中：

λ 增大时，最终 loss 下降，100 轮累计时延略增。

依据：论文图 6、表 4；表中为跨 3 个种子的均值

达到相同 loss 时，比较结果会发生变化

Greedy λ	首次达标轮次	达标累计时延/s
0.25	94.7 ± 3.8	177.28 ± 10.03
0.50	83.0 ± 7.8	157.60 ± 16.21
0.75	74.0 ± 6.0	141.95 ± 11.82

共同目标

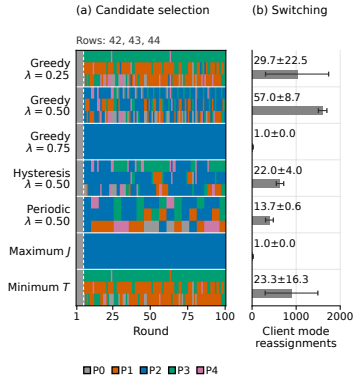
测试 loss ≤ 1.30

三种策略均在
全部 3 个 seed 中达标。

- 单轮偏好较低时延，不一定能更早达到同一个学习目标。
- 在所测权重中，$\lambda = 0.75$ 的平均达标时间最早。

依据：论文第 5.4.1 节与 loss 阈值汇总数据；均值 ± 样本标准差

迟滞与周期控制明显减少模式变化



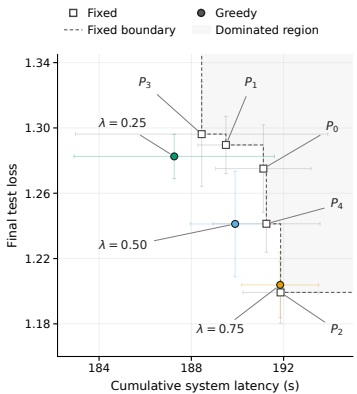
策略	变化次数	减少
Greedy	1601.3	–
Hysteresis	634.0	60.4%
Periodic	394.3	75.4%

均采用 $\lambda = 0.50$。

迟滞的学习表现与 Greedy 相近；周期策略的阈值附近 loss 下降较慢。

依据：论文图 8、表 4；右表为客户端模式变化总次数的跨 seed 均值

动态选择形成不同的终点折中



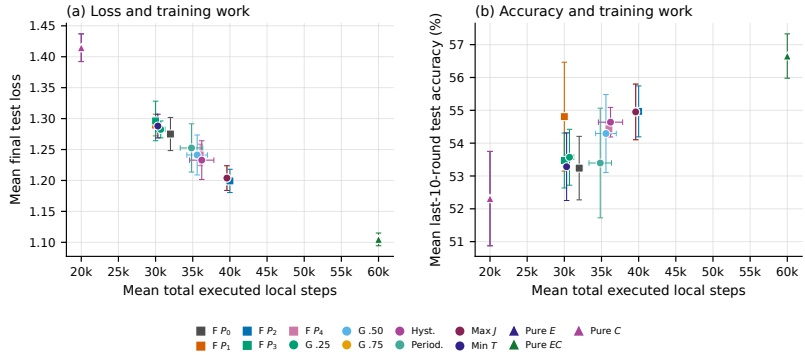
与相近 loss 的固定候选比较

- Greedy 0.25 对比固定 P_3：loss 为 1.2826 / 1.2962，总时延更低。
- Greedy 0.50 对比固定 P_4：loss 均约 1.241，总时延更低。
- Greedy 0.75 接近固定 P_2：学习与时延终点都很接近。

动态策略的收益依赖偏好设置与所选参照策略。

依据：论文图 9 与表 4；比较观察均值，未作显著性优越结论

训练工作量也是学习差异的重要来源



15 个策略均值中：本地步数与 loss 相关系数为 -0.961，与最后 10 轮 accuracy 为 0.915。

— 协作模式与训练量同时变化，需要增加训练量匹配对照

依据：论文图 10 与第 5.5 节；accuracy 统计为 91–100 轮均值

当前结论与证据边界

目前观察到

1. 同状态短期对照中，J 排序与后续 loss 下降排序一致。
2. 在 DP 保护和生命周期预算约束下，效用权重改变学习表现与系统代价的取舍。
3. 迟滞、周期控制可大幅减少客户端模式变化。

仍需进一步验证

- 单数据集、单模型、单拓扑，仅 3 个 seed 和 5 个候选。
- 尚未隔离训练量与隐私噪声的独立影响。
- 时延来自仿真；共享链路竞争和物理部署尚待验证。

当前证据支持将历史偏差作为选择信号，尚不支持准确率预测或因果保证

依据：论文第 5.6 节与结论

下一步计划与组内讨论

后续方向	要回答的问题
训练量匹配对照	控制总步数或计算预算后，协作选择还能带来怎样的收益？
扩大评分检验	在更多共同起点和随机种子上，J 排序是否仍有参考价值？
扩展实验范围	更大模型、更多候选与不同异构场景下，方法是否保持有效？
实际系统验证	增加在线 profiling、链路竞争与物理部署，比较真实运行成本。

希望讨论：下一阶段优先做训练量匹配对照，还是先扩展模型与场景？

依据：论文讨论与 Future work

备查：生命周期预算如何决定噪声倍率

$$\epsilon_i^t = \min_{\alpha \in \mathcal{A}} \left[\Phi_i^t(\alpha) + \frac{\log(1/\delta)}{\alpha - 1} \right] \le \bar{\epsilon}$$

$$\min_{\alpha \in \mathcal{A}} \left[\Phi_i^t(\alpha) + \frac{N_i^t(h)\alpha}{2[\sigma_i^t(h)]^2} + \frac{\log(1/\delta)}{\alpha - 1} \right] \le \bar{\epsilon}$$

- $N_i^t(h)$：选定模式及剩余轮次预计涉及的高斯机制数量。
- 校准依据剩余账本；执行前核验，执行后按实际机制更新。
- 当前实验预算为 $(8, 10^{-5})$，采用不含采样放大的 RDP 核算。

依据：论文第 3.2 节；这里的隐私 ϵ 与 ε」含义不同

备查：15 种策略的主要结果

策略	最终 loss	Accuracy/%	累计 T/s	本地步数	模式变化
固定 P_0	$1.2751 \pm .0268$	$53.24 \pm .97$	191.122	32000	0
固定 P_1	$1.2896 \pm .0175$	54.81 ± 1.66	189.498	30000	0
固定 P_2	$1.1992 \pm .0188$	$54.97 \pm .78$	191.868	40000	0
固定 P_3	$1.2962 \pm .0320$	$53.47 \pm .84$	188.447	30000	0
固定 P_4	$1.2413 \pm .0174$	$54.44 \pm .17$	191.253	36000	0
Greedy .25	$1.2826 \pm .0136$	$53.57 \pm .85$	187.258	30693	1021.7
Greedy .50	$1.2412 \pm .0323$	54.29 ± 1.19	189.896	35600	1601.3
Greedy .75	$1.2038 \pm .0200$	$54.95 \pm .85$	191.851	39600	20.0
Hysteresis .50	$1.2329 \pm .0313$	$54.64 \pm .45$	189.909	36213	634.0
Periodic .50	$1.2526 \pm .0390$	53.40 ± 1.67	190.154	34833	394.3
Maximum J	$1.2038 \pm .0200$	$54.95 \pm .85$	191.851	39600	20.0
Minimum T	$1.2880 \pm .0192$	53.28 ± 1.03	187.245	30307	895.0
纯 FL_E	$1.4146 \pm .0224$	52.31 ± 1.44	73.117	20000	0
纯 FL_{EC}	$1.1047 \pm .0103$	$56.65 \pm .68$	185.558	60000	0
纯 FL_C	$1.4146 \pm .0224$	52.31 ± 1.44	83.733	20000	0

依据：论文表 4；loss 与 accuracy 列保留样本 SD，其余列为均值；accuracy 为 91–100 轮均值

备查：历史统计、初始化与计算成本

$$
\begin{aligned}
v_g^{\tau-1} &= \gamma_C v_g^{\tau-2} + (1-\gamma_C)\Delta_C^{\tau-1},\\
d_k^{\tau} &= u_{k,\mathrm{DP}}^{\tau} - v_g^{\tau-1},\\
\bar{d}_m^{\tau} &= \frac{\sum_{k\in\mathcal{K}_m^{\tau}} I_k^{\tau} d_k^{\tau}}{\sum_{k\in\mathcal{K}_m^{\tau}} I_k^{\tau}},\\
\widehat{d}_m^{t} &= \gamma_d \widehat{d}_m^{t-1} + (1-\gamma_d)\bar{d}_m^{t-1}.
\end{aligned}
$$

- 首次可用观测初始化；某模式没有新观测时保留原估计。
- 前 5 轮的 P_0 用于收集三种模式的历史。
- 动态策略平均每轮选择计算约 7.34–7.68 ms，单独记录。

依据：论文第 3.3.2 节、第 5.2 节与第 5.5 节

备查：实验结果应如何解读

两类实验分别回答不同问题

- 短期 pilot：在同一决策状态下，比较候选初始评分与后续 loss 变化。
- 完整训练：比较 15 种策略在 100 轮中的学习、时延与切换结果。
- 主实验使用 3 个种子；pilot 为 seed42 单次对照，二者不合并统计。

图与数值的解释规则

- 均值和样本 SD 反映当前三种子的观测；未作显著性优越结论。
- 隐私保护影响包含在历史更新中，未单独识别噪声的因果效应。
- 后续计划均单独标注，未作为已完成成果展示。

依据：论文第 5 节实验设计、统计口径与讨论